

# 1 线性可分支持向量机 (硬间隔最大化)

对于约束最优化问题:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (1)$$

$$s.t \quad y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \quad (2)$$

易知式 (2) 满足等号“=”的样本点实例为支持向量。

运用拉格朗日乘数法, 定义拉格朗日函数:

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i \cdot (y_i(w \cdot x_i + b) - 1) \quad (3)$$

$$= \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \quad (4)$$

即该问题是来探究  $\max_{\alpha} \min_{w,b} L(w, b, \alpha)$ , 因此需要先求  $L(w, b, \alpha)$  对  $w, b$  的极小, 再求对  $\alpha$  的极大.

(1) 先求  $L(w, b, \alpha)$  对  $w, b$  的极小根据式 (4) 分别对  $w, b$  求偏导数并令其等于 0

对  $w$ ,

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad (5)$$

对  $b$ ,

$$\nabla_b L(w, b, \alpha) = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (6)$$

因此有

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (7)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (8)$$

把式 (7) 代入 (4) 可得到如下公式:

$$L(w, b, \alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left( \left( \sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \quad (9)$$

又因为式 (8)，因此式 (9) 的第二式中  $\sum_{i=1}^N \alpha_i y_i b = 0$ ，因此有：

$$L(w, b, \alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left( \left( \sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i \right) + \sum_{i=1}^N \alpha_i \quad (10)$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (11)$$

$$= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (12)$$

即

$$\min_{w, b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (13)$$

(2) 再求  $\min_{w, b} L(w, b, \alpha)$  对  $\alpha$  的极大，即：

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (14)$$

$$s.t \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (15)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N \quad (16)$$

将式 (14) 的目标函数由求极大值转换为求极小值，就得到下面与之等价的对偶问题：

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (17)$$

$$s.t \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (18)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N \quad (19)$$

我们需要求解(利用SMO算法)) 得到最优解  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$  我们选择一个  $\alpha_j^* > 0$ ，这样我们能够求得原始目标优化问题 (1) 的解为：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (20)$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (21)$$

于是可以求得分离超平面及分类决策函数

$$w^* \cdot x + b^* = 0 \quad (22)$$

$$f(x) = \text{sign}(w^* \cdot x + b^*) \quad (23)$$

## 2 线性支持向量机 (软间隔最大化)

其中凸二次优化的原始问题为：

$$\min_{w, b, \xi} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (24)$$

$$s.t. \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \quad (25)$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, N \quad (26)$$

我们需要求解该原始问题 (24) 的对偶问题, 先写出拉格朗日函数：

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i(w \cdot x_i) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i \quad (27)$$

其中,  $\alpha_i \geq 0, \mu_i \geq 0$ .

与前面同理, 先求  $L(w, b, \xi, \alpha, \mu)$  对  $w, b, \xi$  的极小：

$$\nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad (28)$$

$$\nabla_b L(w, b, \xi, \alpha, \mu) = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (29)$$

$$\nabla_{\xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \mu_i = 0 \quad (30)$$

这样，可以得到：

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (31)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (32)$$

$$C - \alpha_i - \mu_i = 0 \quad (33)$$

将式 (31) , (32) , (33) 代入式 (27), 可得到

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (34)$$

再全对  $\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu)$  求  $\alpha$  的极大，即得到对偶问题：

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (35)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (36)$$

$$C - \alpha_i - \mu_i = 0 \quad (37)$$

$$\alpha_i \geq 0 \quad (38)$$

$$\mu_i \geq 0, \quad i = 1, 2, \dots, N \quad (39)$$

利用式 (37) 消去  $\mu_i$ ，可得到如下对偶问题：

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (40)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (41)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \quad (42)$$

这里， $C > 0$  成为惩罚参数，一般由应用问题决定， $C$  值大时对误分类的惩罚增大， $C$  值小时对误分类的惩罚减小

目标是：使间隔尽量大同时使误分类点的个数尽量小

分类超平面及其决策函数与线性可分线性向量机的相似，只是分量选择为  $0 \leq \alpha_j^* \leq C$ 。

### 3 序列最小最优化算法 (Sequential minimal optimization) SMO 算法来求解 $\alpha$

SMO 算法是一种启发式算法，如果所有变量的解都满足此最优问题的 KKT 条件 (Karush-Kuhn-Tucker conditions)，那么这个最优化问题的解就得到了。

在这里用非线性支持向量机学习算法：即 SMO 算法要求解如下凸二次优化问题：

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad (43)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (44)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \quad (45)$$

整个 SMO 算法包括两部分：

1. 求解两个变量的二次规划的解析方法
2. 选择变量的启发式方法

#### 3.1 两个变量二次规划的求解方法

不失一般性，将假设选择的  $\alpha_1$  与  $\alpha_2$  作为自变量，而将其它  $\alpha_i (i = 3, 4, \dots, N)$  进行固定，这样的 (43) 优化问题可以转写为

$$\min_{\alpha_1, \alpha_2} \quad W(\alpha_1, \alpha_2) = \frac{1}{2} \alpha_1^2 y_1^2 K_{11} + \frac{1}{2} \alpha_2^2 y_2^2 K_{22} + \frac{1}{2} \alpha_1 \alpha_2 y_1 y_2 K_{12} + \frac{1}{2} \alpha_2 \alpha_1 y_2 y_1 K_{21} - \sum_{i=1}^N \alpha_i \quad (46)$$

$$+ \frac{1}{2} \alpha_1 y_1 \sum_{i=3}^N y_i \alpha_i (K_{i1} + K_{1i}) + \frac{1}{2} \alpha_2 y_2 \sum_{i=3}^N y_i \alpha_i (K_{i2} + K_{2i}) + \frac{1}{2} \sum_{i=3}^N \sum_{j=3}^N \alpha_i \alpha_j y_i y_j K_{ij} \quad (47)$$

问题可以转换为

$$\min_{\alpha_1, \alpha_2} W(\alpha_1, \alpha_2) = \frac{1}{2}K_{11}\alpha_1^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_1y_2K_{12}\alpha_1\alpha_2 - (\alpha_1 + \alpha_2) + y_1\alpha_1 \sum_{i=3}^N y_i\alpha_i K_{i1} + y_2\alpha_2 \sum_{i=3}^N y_i\alpha_i K_{i2} \quad (48)$$

$$s.t. \quad \alpha_i y_i + \alpha_2 y_2 = - \sum_{i=3}^N y_i \alpha_i = \varsigma \quad (49)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2 \quad (50)$$

式 (49) 同时乘上  $y_1$

$$\alpha_1 y_1^2 + \alpha_2 y_1 y_2 = y_1 \varsigma \quad (51)$$

$$\alpha_1 = y_1(\varsigma - \alpha_2 y_2) \quad (52)$$

代入 (48),

$$W(\alpha_2) = \frac{1}{2}K_{11}(\varsigma - \alpha_2 y_2)^2 + \frac{1}{2}K_{22}\alpha_2^2 + K_{12}y_2(\varsigma - \alpha_2 y_2)\alpha_2 - y_1\varsigma + (y_1 y_2 - 1)\alpha_2 + (\varsigma - \alpha_2 y_2) \sum_{i=1}^N y_i \alpha_i K_{i1} + y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{i2} \quad (53)$$

在这里, 令  $v_1 = \sum_{i=1}^N y_i \alpha_i K_{i1}, v_2 = \sum_{i=3}^N y_i \alpha_i K_{i2}$  上式可化简为

$$W(\alpha_2) = \frac{1}{2}K_{11}(\varsigma - \alpha_2 y_2)^2 + \frac{1}{2}K_{22}\alpha_2^2 + K_{12}y_2(\varsigma - \alpha_2 y_2)\alpha_2 - y_1(\varsigma - \alpha_2 y_2) - \alpha_2 + v_1(\varsigma - \alpha_2 y_2) + y_2 v_2 \alpha_2 \quad (54)$$

$W(\alpha_2)$  对  $\alpha_2$  求导数得到:

$$\begin{aligned} \frac{\partial W}{\partial \alpha_2} &= K_{11}y_2(\alpha_2 y_2 - \varsigma) + K_{22}\alpha_2 + y_2 K_{12}\varsigma - 2K_{12}\alpha_2 + y_1 y_2 - 1 - v_1 y_2 + y_2 v_2 \\ &= K_{11}\alpha_2 + K_{22}\alpha_2 - 2K_{12}\alpha_2 - K_{11}\varsigma y_2 + K_{12}\varsigma y_2 + y_1 y_2 - 1 - v_1 y_2 + y_2 v_2 \end{aligned} \quad (55)$$

令其为 0, 又考虑到 SVM 对数据点的预测值为

$$g(x) = \sum_{i=1}^N \alpha_i y_i K(x_i, x) + b \quad (56)$$

在此, 令

$$E_i = g(x_i) - y_i = \left( \sum_{j=1}^N \alpha_j y_j K(x_j, x_i) + b \right) - y_i, \quad i = 1, 2 \quad (57)$$

令 (55) 为 0, 并将  $\varsigma = \alpha_1^{old}y_1 + \alpha_2^{old}y_2$  代入, 得到

$$(K_{11} + K_{22} - 2K_{12})\alpha_2^{new,unc} = (K_{11} + K_{22} - 2K_{12})\alpha_2^{old} + y_2(E_1 - E_2) \quad (58)$$

将  $\eta = K_{11} + K_{22} - 2K_{12}$  代入, 有

$$\alpha_2^{new,unc} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta} \quad (59)$$

还需要对原始解进行修剪

当  $y_1 \neq y_2$  时, 上下界表示为:

下界:  $L = \max(0, \alpha_2^{old} - \alpha_1^{old})$  上界:  $H = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$

当  $y_1 = y_2$  时, 上下界表示为:

下界:  $L = \max(0, \alpha_2^{old} + \alpha_1^{old} - C)$  上界:  $H = \min(C, \alpha_2^{old} + \alpha_1^{old})$

经过修剪后的  $\alpha_2$ :

$$\alpha_2^{new} = \begin{cases} H, & \alpha_2^{new,unclipped} > H \\ \alpha_2^{new,unclipped}, & L \leq \alpha_2^{new,unclipped} \leq H \\ L, & \alpha_2^{new,unclipped} < L \end{cases}$$

又因为公式

$$\alpha_1^{old}y_1 + \alpha_2^{old}y_2 = \alpha_1^{new}y_1 + \alpha_2^{new}y_2 = \varsigma \quad (60)$$

我们可以计算出  $\alpha_1^{new}$

## 3.2 变量选择的方法

### 3.2.1 阈值 b 的更新

当  $0 < \alpha_1^{new} < C$  时,

$$b_1^{new} = y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21} \quad (61)$$

由式 (57) 式我们可以得到

$$E_1 = \left( \sum_{j=1}^N \alpha_j y_j K(x_j, x_1) + b^{old} \right) - y_1 \quad (62)$$

$$= \sum_{i=3}^N \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1 \quad (63)$$

由此可得

$$y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} = -E_1 + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} \quad (64)$$

代入式 (61), 得

$$b_1^{new} = -E_1 - y_1 K_{11}(\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{21}(\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (65)$$

同理, 当  $0 < \alpha_2^{new} < C$  时, 有:

$$b_2^{new} = -E_2 - y_1 K_{12}(\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{22}(\alpha_2^{new} - \alpha_2^{old}) + b^{old} \quad (66)$$

并且, 每次对两个变量进行优化之后, 还需要更新对应的  $E_i$  值, 并将它们保存在列表中:

$$E_i^{new} = \sum_S y_j \alpha_j K(x_i, x_j) + b^{new} - y_i \quad (67)$$

其中,  $S$  是所有支持向量的集合